计算机视觉核心知识

CNN、Transformer、视觉任务与相机模型

面向论文阅读的非官方中文学习笔记

2026 年 11 月

摘要

本笔记依据当前材料包中的 Stanford CS231n 四讲与 CS231A 相机模型讲义编写，重点解释概念、公式、数据流、实验指标与 3D 论文阅读。它是按学习目标重新组织的笔记，不是官方译本；MIT 深度学习基础笔记见本仓库另一个 PDF。个别指标与 3D 应用为帮助阅读论文而补充，文中明确标示。

目录

1 阅读地图与基本符号 **2**

2 CNN：从像素到特征（CS231n L5） **2**

3 CNN 训练与网络架构（CS231n L6） **3**

4 注意力与 Transformer（CS231n L8） **3**

5 视觉任务、预测与评测（CS231n L9） **4**

6 相机模型与 3D 视觉（CS231A Camera Models） **5**

7 论文阅读练习与参考答案 **6**

8 来源与版本 **6**

1 阅读地图与基本符号

研究论文可沿着**输入数据 → 特征提取 → 任务预测 → 训练目标 → 评测追踪**。视觉模型的输入常用张量表示。下文约定图像批次为 $X \in \mathbb{R}^{N\times C\times H\times W}$，其中 N 是批大小，C 是通道数，H, W 是高度与宽度。也有代码使用 NHWC 排列，必须查实现而不能只看数字。

CNN 通过局部卷积、共享权重和逐层组合提取图像特征；Transformer 通过注意力在 token 之间传递信息；检测、分割等任务决定输出格式；相机模型将 3D 几何与 2D 图像联系起来。训练、损失与梯度基础请先参阅本仓库的 MIT 笔记。

2 CNN：从像素到特征（CS231n L5）

2.1 图像特征、卷积和权重共享

直接把 $32 \times 32 \times 3$ 图像拉直成 3072 维向量，会忽略网络结构中的空间邻近关系。卷积核每次处理局部区域，并在不同位置复用相同的权重。对于一个输出通道，深度学习中常见的卷积实现实际上采用互相关：

$$y_{o,i,j} = b_o + \sum_{c=1}^{C_{\text{in}}} \sum_{u=0}^{K-1} \sum_{v=0}^{K-1} W_{o,c,u,v}\, x_{c,\, is+u-p,\, js+v-p}.$$

其中 K 是核大小，s 为步长，p 为填充；越界位置按填充规则处理。每个输出通道对应一组覆盖全部输入通道的卷积核，所有位置共享该组权重。偏置若每个输出通道一个，则参数数量为

$$C_{\text{out}}(C_{\text{in}}K^2 + 1).$$

例：输入 $3 \times 32 \times 32$，使用 16 个 3×3 核、步长 1、填充 1，输出为 $16 \times 32 \times 32$，参数数为 $16(3 \cdot 3 \cdot 3 + 1) = 448$。若不计偏置则为 432。

2.2 尺寸、感受野与下采样

对方形核且无 dilation 的情况，输出高度为

$$H_{\text{out}} = \left\lfloor \frac{H + 2p - K}{s} \right\rfloor + 1,$$

宽度同理。例：$H = 32, K = 3, p = 1, s = 2$，得到 $H_{\text{out}} = 16$。stride 变大通常降低空间分辨率。**感受野**是某个输出可能依赖的输入区域；连续两层 3×3、stride 1 的卷积理论感受野从 3×3 增至 5×5。若存在下采样或 dilation，需逐层计算。

最大池化在局部窗口内取最大值，常用于下采样；卷积也可以通过 stride 下采样。分辨率降低节省计算并扩大后续特征的有效覆盖范围，但可能损失精细位置。实际网络可借助多尺度或跳跃连接恢复细节。

在适当的边界和步长条件下，卷积具有平移等变性：输入平移，输出特征也相应平移；这不等于分类结果对任意平移都严格不变。填充、下采样和边界会影响这种性质。

2.3 读论文时检查

看网络图时记录每个阶段的 (C, H, W)、卷积核与 stride。**Backbone** 通常提取特征，**head** 将特征变成特定任务预测。卷积层输出的不同通道是学得的特征，不应简单等同于人类可命名的概念。L5 建议重点看 PDF 第 47–68、69–94、100–105 页。

3 CNN 训练与网络架构（CS231n L6）

3.1 归一化、非线性与残差

归一化层按某些维度计算统计量并变换激活；例如 LayerNorm 通常对每个样本的特征维做归一化。具体归一化维度取决于网络与实现，不应将 LayerNorm 和 BatchNorm 混为一谈。ReLU、GELU 等激活引入非线性；初始化影响初期激活和梯度的尺度。

VGG 将多层卷积堆叠；ResNet 的残差块写作

$$y = x + F(x; \theta).$$

F 学习一个变换，旁路把 x 送到加法节点。当形状不相容时，实际实现需要投影或调整维度。残差路径有助于优化深层网络，但不意味着网络天然不会过拟合。

3.2 训练策略

- **初始化**：若初始权重太小或太大，激活与梯度可能衰减或爆炸。常见初始化根据输入维度和激活函数设定尺度；具体方案需匹配网络。
- **输入归一化**：按训练设置对图像各通道中心化和缩放，评测时保持一致。
- **数据增强**：翻转、随机裁剪、颜色扰动等可增加训练样本变化，但变换必须保留当前任务的正确标签；例如某些方向敏感任务不能随意翻转。
- **迁移学习**：预训练 backbone 后，可冻结特征提取器训练新 head，或对部分或全部参数微调。比较方法时要检查预训练数据和权重。
- **超参数诊断**：观察训练与验证曲线、初始 loss、学习率与训练时间；验证集有助于选超参数，测试集用于最终评估。

L6 重点看第 11–20、24–31、46–58、60–76、78–96 页。阅读实验设置时记录输入尺寸、优化器、batch size、预训练、训练预算与数据增强，避免只比较最后一列分数。

4 注意力与 Transformer（CS231n L8）

4.1 从加权求和理解注意力

注意力用输入相关的权重聚合信息。对于 token 表示 $X \in \mathbb{R}^{N \times d}$，线性投影得到 $Q = XW_Q$、$K = XW_K$、$V = XW_V$。若 $Q, K \in \mathbb{R}^{N \times d_k}$、$V \in \mathbb{R}^{N \times d_v}$，则

$$A = \mathrm{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}}\right), \qquad Y = AV.$$

$A \in \mathbb{R}^{N\times N}$，softmax 沿每个查询对应的键位置计算；每行的权重和为 1。A_{ij} 描述第 i 个查询对第 j 个 value 的聚合权重。比如某行权重为 $(0.7, 0.2, 0.1)$，输出是 $0.7v_1 + 0.2v_2 + 0.1v_3$。

自注意力中的 Q, K, V 来自同一组 token；交叉注意力通常由一组 token 产生查询，另一组产生键和值。多头注意力并行计算多组投影及注意力，再合并。注意力权重可帮助观察模型的信息聚合，但单凭权重不能直接证明因果解释。

4.2 位置、复杂度与 Transformer block

仅使用上述无位置自注意力时，置换输入 token 会相应置换输出；模型需要通过位置编码等机制获取顺序或空间位置。标准全局注意力显式形成 $N \times N$ 的分数矩阵，随 token 数增长通常有二次计算与存储压力；不同实现和近似方法可改变实际内存开销。

一个典型 Transformer block 包含注意力、逐 token 的 MLP、残差连接和归一化。具体为 pre-norm 还是 post-norm，激活与注意力实现如何，应依论文或代码为准。自回归语言建模常用因果 mask 防止访问未来 token；视觉编码器并非都使用因果 mask。

4.3 视觉 Transformer（ViT）

将大小 $H \times W$ 的图像切为 $P \times P$ patch，若尺寸可整除，则 token 数为 $N = (H/P)(W/P)$。每个 patch 展平并投影到 d 维，加入位置信息后输入 Transformer。分类输出可使用特殊 token 或对输出 token 做池化；实现因模型而异。

例：224×224 图像、16×16 patch，得到 $14 \times 14 = 196$ 个图像 token（若额外加入分类 token，序列会更长）。patch 更小通常增加 token 数及全局注意力成本。L8 重点看第 13–19、63–79、85–93、101–110 页。

5 视觉任务、预测与评测（CS231n L9）

5.1 任务区别

任务	输出	两只猫的例子
分类	整图类别或分数	图中有猫
检测	类别、置信度与边界框	分别框出两只猫
语义分割	每个像素的类别	猫像素都标为猫
实例分割	每个实例的类别与掩码	分开标出每只猫的像素

语义分割需要逐像素结果。全卷积网络可先下采样提取语义，再上采样恢复空间分辨率；U-Net 将高分辨率编码器特征与解码器特征连接，帮助恢复细节。上采样可以用插值或可学习算子；转置卷积不是普通卷积的通用数学逆运算。

5.2 检测与实例分割

检测模型必须处理一张图中目标数量不固定的问题。两阶段检测器先提出候选区域，再进行分类和边界框修正；单阶段检测器直接从特征预测多个候选。经典 R-CNN 系列、YOLO 和 DETR

的具体实现不同，不能把所有版本当成同一个模型。DETR 直接预测一个集合，并通过匹配训练使预测与目标对应。Mask R-CNN 在检测框架中增加实例掩码预测分支。

5.3 指标补充：IoU、AP 与公平比较

以下指标解释是论文阅读补充，不假设 L9 完整涵盖了所有指标。对于预测区域 A 和真实区域 B：

$$\mathrm{IoU}(A,B)=\frac{|A\cap B|}{|A\cup B|}.$$

IoU 可用于框或掩码；需结合匹配规则与阈值。检测中 precision 为预测正例中正确的比例，recall 为真实目标中被检出的比例；AP 汇总精确率与召回率的关系，mAP 通常对多个类别及可能的 IoU 阈值取平均。不同基准的 AP 定义和阈值可能不同，比较时要查协议。语义分割的 mIoU 通常先计算各类别的 IoU 再平均，同样需要确认忽略类别等规则。

比较论文表格时记录数据集与划分、训练数据和预训练、输入分辨率、指标及阈值、训练预算、计算量和模型规模。不应将不同协议的数字直接排名。可视化中的 saliency、CAM、Grad-CAM 是分析工具，热图并不自动证明模型的因果依据。L9 重点看第 30–63、65–111、112–122、128–145 页。

6 相机模型与 3D 视觉（CS231A Camera Models）

6.1 针孔投影：三维点到二维像素

先固定坐标约定：设三维点在相机坐标系中为 $\mathbf{X}_c=(X_c,Y_c,Z_c)^{\mathsf{T}}$，取朝前的 $Z_c>0$，并将图像平面表述为正向投影。无畸变时，归一化图像坐标为 $x=X_c/Z_c$、$y=Y_c/Z_c$；若忽略 skew，像素坐标为

$$u=f_xX_c/Z_c+c_x,\qquad v=f_yY_c/Z_c+c_y.$$

例如 $\mathbf{X}_c=(1,0.5,2)$、$f_x=f_y=800$、$(c_x,c_y)=(320,240)$，得到 $(u,v)=(720,440)$。在同一射线上的 $(2,1,4)$ 也投影到这个像素：**单个像素不能独自确定深度**。不同教材可能采用不同图像平面、轴方向和符号约定，不能脱离约定照搬符号。

6.2 齐次坐标、内参与外参

用 $\tilde{\mathbf{u}}=(u,v,1)^{\mathsf{T}}$ 和 $\tilde{\mathbf{X}}_w=(X_w,Y_w,Z_w,1)^{\mathsf{T}}$ 表示齐次坐标，一种常见的世界到相机约定为

$$\lambda\tilde{\mathbf{u}}=K[R\mid t]\tilde{\mathbf{X}}_w,\quad K=\begin{bmatrix}f_x & s & c_x\\ 0 & f_y & c_y\\ 0 & 0 & 1\end{bmatrix},\quad \mathbf{X}_c=R\mathbf{X}_w+t.$$

K 为内参，s 为 skew；R,t 为上述方向约定下的外参。齐次向量差一个非零尺度代表同一投影点；需要除以第三分量才能获得像素坐标。相机中心满足 $R\mathbf{C}_w+t=0$，所以 $\mathbf{C}_w=-R^{\mathsf{T}}t$。这说明外参中的 t 并不直接等于世界坐标下的相机位置。

如果论文给的是相机到世界的位姿，则需先求逆：$R_{wc}=R_{cw}^{\mathsf{T}}$、$t_{wc}=-R_{cw}^{\mathsf{T}}t_{cw}$。上标或下标习惯各异，务必从作者定义核对方向。旋转矩阵满足 $R^{\mathsf{T}}R=I$ 且 $\det R=1$。

6.3 射线、标定和近似模型

若已知内参且忽略畸变，像素 (u, v) 对应相机坐标系方向 $\mathbf{d}_c \propto K^{-1}(u, v, 1)^{\mathsf{T}}$。将方向转到世界坐标，可用世界空间的相机中心 $\mathbf{C}_w$ 表示射线：

$$\mathbf{r}(\tau) = \mathbf{C}_w + \tau \mathbf{d}_w, \qquad \tau \geq 0.$$

这是多视角重建与渲染中的常见起点；τ 与相机 Z 深度是否相同取决于射线方向的归一化和定义。

相机标定通过已知几何和图像对应关系估计内参与外参；可使用棋盘等标定物，结果会受观测噪声和退化配置影响。真实镜头存在径向等畸变，理想针孔公式不能直接覆盖所有镜头。**弱透视**适用于物体深度变化相对平均距离较小的近似情形，用近似固定的深度替代逐点深度；**正交投影**进一步忽略深度造成的透视缩放。这些是近似模型，不应在显著透视变化下无条件使用。

阅读 3D 论文时明确：像素坐标与分辨率、内参是否随缩放改变、位姿方向、单位、坐标轴朝向、是否去畸变、深度定义以及训练和测试视角如何划分。CS231A 笔记第 1–9 页覆盖针孔与内外参，第 10–13 页涉及标定，第 14–17 页涉及变换与近似投影。

7 论文阅读练习与参考答案

1. 输入 $3 \times 32 \times 32$，16 个 3×3 卷积核，stride 2、padding 1，输出尺寸与参数量是多少（计偏置）?
2. 图像大小 224×224，patch 为 16×16，ViT 得到多少图像 token? 全局注意力分数矩阵有多大?
3. 两只猫被同一种标签覆盖，无法区分各自像素，这符合语义分割还是实例分割?
4. 某点相机坐标为 $(1, 0, 2)$，另一个是 $(2, 0, 4)$。理想针孔投影中它们为什么可能落在同一像素?
5. 如果一个方法的 AP 比另一个高，判断优劣前还应核对哪些条件?

参考答案：（1）$16 \times 16 \times 16$；参数 $16(3 \cdot 3 \cdot 3 + 1) = 448$。（2）196 个；不含额外 token 时为 196×196。（3）语义分割。（4）它们的 X/Z 和 Y/Z 相同，位于同一相机射线上。（5）数据集和划分、预训练、指标阈值、输入、训练预算及计算成本等。

8 来源与版本

原始资料为官方课程文件，本仓库不再分发原始讲义。CS231n L5 虽由 2026 课程链接提供，但原 PDF 页脚仍标 2025；CS231A 相机讲义为未标年份的通用笔记。

- CS231n L5: https://cs231n.stanford.edu/slides/2026/lecture_5.pdf
- CS231n L6: https://cs231n.stanford.edu/slides/2026/lecture_6.pdf
- CS231n L8: https://cs231n.stanford.edu/slides/2026/lecture_8.pdf
- CS231n L9: https://cs231n.stanford.edu/slides/2026/lecture_9.pdf
- CS231A Camera Models 官方讲义