深度学习入门

面向计算机视觉论文阅读的学习笔记

基于 MIT 6.S191 2026 Lecture 1 整理的非官方笔记

2026 年 11 月

摘要

本笔记围绕神经网络的前向计算、损失、梯度、反向传播、优化与泛化，整理理解视觉论文所需的基础概念。正文包含数值算例、维度检查、常见论文术语和练习答案。课件中关于课程安排的内容从略；本笔记是重新组织的学习材料，不是官方逐页译本。

目录

1 一张训练流程图 **2**

2 神经元与激活函数 **2**

2.1 加权求和 2

2.2 激活与非线性 2

3 多层网络与维度 **2**

4 损失函数：把错误变成数值 **3**

4.1 二分类交叉熵 3

4.2 均方误差与经验损失 3

5 优化：用梯度更新参数 **3**

6 反向传播：链式法则 **3**

7 批次、训练轮次与优化 **4**

8 泛化、数据划分与正则化 **4**

9 从术语进入论文 **4**

10 自测与答案 **5**

11 课件定位与来源 **5**

1 一张训练流程图

深度学习模型可以写为 $\hat{y} = f_\theta(x)$：x 是输入，$\hat{y}$ 是预测，θ 是可学习参数。给定目标 y，用损失函数 $L(\hat{y}, y)$ 衡量预测与目标的差距。一次训练更新的主线为

$$\text{输入数据} \to \text{前向计算} \to \text{损失} \to \text{反向传播求梯度} \to \text{优化器更新参数}.$$

参数由训练学习，例如权重与偏置；**超参数**由实验配置，例如学习率、批大小和网络结构。训练用数据调整参数；推理用已确定的参数作预测。

2 神经元与激活函数

2.1 加权求和

神经元先对输入加权并加上偏置，再应用激活函数：

$$z = w_1 x_1 + w_2 x_2 + b = \mathbf{w}^\mathsf{T}\mathbf{x} + b, \qquad \hat{y} = g(z).$$

例如 $z = 0.3x_1 + 0.2x_2 - 1$，当 $x_1 = 4, x_2 = 5$ 时，$z = 1.2$。权重控制输入变化对该神经元输出的影响，偏置调整变换的截距；深层网络中的单个权重一般不应被直接解释为因果效应。

2.2 激活与非线性

Sigmoid 函数 $\sigma(z) = 1/(1 + e^{-z})$ 将实数映射到 $(0, 1)$；对上述例子，$\sigma(1.2) \approx 0.769$。若输出被定义为二分类的概率，则可把它视为正类的预测概率。ReLU 定义为 $\mathrm{ReLU}(z) = \max(0, z)$，例如 $\mathrm{ReLU}(-3) = 0$、$\mathrm{ReLU}(2) = 2$。Tanh 的输出范围为 $(-1, 1)$。

激活函数使网络能够表示非线性关系。若没有非线性，两层仿射变换仍可合并成一层：

$$W_2(W_1 x + b_1) + b_2 = (W_2 W_1)x + (W_2 b_1 + b_2).$$

因此，单纯叠加仿射层不会增加整体函数的非线性表达能力。

3 多层网络与维度

考虑一个含隐藏层的网络：

$$h = \mathrm{ReLU}(W_1 x + b_1), \qquad \hat{y} = \sigma(W_2 h + b_2).$$

若 $x \in \mathbb{R}^2$、$h \in \mathbb{R}^3$、输出为标量，则 $W_1 \in \mathbb{R}^{3\times 2}$、$b_1 \in \mathbb{R}^3$、$W_2 \in \mathbb{R}^{1\times 3}$、$b_2 \in \mathbb{R}$。参数总数为 $3 \times 2 + 3 + 1 \times 3 + 1 = 13$。全连接层（dense / fully connected layer）把每个输入分量连接到每个输出分量。多层感知机（MLP）通常由多层全连接层和激活函数组成。

读论文时：先标记各变量的维度，追踪输入、隐藏表示和输出，再判断哪些矩阵是可学习参数。现代网络也会使用卷积、注意力等模块，但仍可以沿数据流追踪。

4 损失函数：把错误变成数值

4.1 二分类交叉熵

对于标签 $y \in \{0,1\}$、正类预测概率 $p \in (0,1)$，二分类交叉熵为

$$L_{\mathrm{BCE}}(p,y) = -\big[y\log p + (1-y)\log(1-p)\big],$$

其中 log 为自然对数。若真实标签 $y=1$，损失简化为 $-\log p$：

预测概率 p	0.9	0.5	0.1
损失 $-\log p$	0.105	0.693	2.303

对错误预测越有信心，损失通常越大。实际实现常直接使用 logits（Sigmoid 前的分数）计算交叉熵，以改善数值稳定性。

4.2 均方误差与经验损失

回归任务可使用平方误差；预测 75、真实值 80 时，单样本平方误差为 $(75-80)^2 = 25$。对于 N 个样本，平均经验损失可以写成

$$J(\theta) = \frac{1}{N}\sum_{i=1}^{N} L\big(f_\theta(x_i), y_i\big).$$

具体任务应根据输出、数据和目标选择损失。论文中的 $L = L_{\mathrm{recon}} + \lambda L_{\mathrm{reg}}$ 表示总目标由重建损失和加权正则项组成；要进一步查明重建目标、正则化对象和 λ 的选择方式。

5 优化：用梯度更新参数

训练常写成 $\theta^* = \arg\min_\theta J(\theta)$，即寻找使训练目标较小的参数。深度学习的优化一般不保证找到全局最优。

梯度描述损失在当前位置对参数的局部变化。梯度下降更新为

$$\theta \leftarrow \theta - \eta \nabla_\theta J(\theta),$$

其中 η 是学习率。若 $w=2$、$\partial J/\partial w = 3$、$\eta = 0.1$，则更新后 $w = 1.7$；若梯度为 -3，则更新后 $w = 2.3$。学习率太小可能使训练很慢，太大可能使训练不稳定或发散。SGD、Adam 等优化器使用梯度生成更新；Adam 根据梯度历史调整更新尺度，仍需设置学习率。

6 反向传播：链式法则

前向传播负责计算预测与损失；反向传播沿计算图使用链式法则计算梯度；优化器随后使用梯度更新参数。

设 $\hat{y} = wx$、$L = (\hat{y}-y)^2$，取 $x=2, w=1, y=3$。前向计算得 $\hat{y}=2$，$L=1$。反向计算：

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial \hat{y}}\frac{\partial \hat{y}}{\partial w} = 2(\hat{y}-y)x = 2(2-3)\times 2 = -4.$$

令 $\eta = 0.1$，更新为 $w_{\text{new}} = 1 - 0.1(-4) = 1.4$。再次预测为 2.8，损失为 0.04。这是一个单样本例子；真实网络有大量参数，自动微分框架会处理相同的链式法则。

7 批次、训练轮次与优化

- **Batch**：一次共同处理的一组样本；batch size 是其大小。
- **Iteration / step**：通常指处理一批数据并进行一次参数更新，具体实现可能有梯度累积等差异。
- **Epoch**：训练集被遍历一遍。

例如训练集有 1000 个样本，batch size 为 100，每个样本每轮使用一次且每批更新一次，则一个 epoch 有 10 次更新。小批次允许并行计算，并用批次梯度近似全数据梯度；批大小还影响内存、速度和优化行为。

8 泛化、数据划分与正则化

模型的训练表现好并不自动意味着对未见数据表现也好。**过拟合**表现为训练结果很好，但在合适的未见数据上明显变差；**欠拟合**则可能表现为训练与验证均较差。差距还可能来自训练与验证分布不同或评测设置等，需要进一步检查。

- **训练集**：用于计算梯度、调整参数。
- **验证集**：用于选择超参数、模型检查点和停止时机。
- **测试集**：用于最终评估；反复依据测试结果调整模型会削弱其独立评估作用。

Dropout 在训练时随机将部分激活置零；比例与使用位置依任务而定，推理时一般关闭。**Early stopping** 可以根据验证集表现停止训练或选择最优检查点。课件示意图将监控曲线标为 testing；规范实践中应使用验证集作模型选择，保留测试集用于最终评估。

9 从术语进入论文

术语	阅读时的含义
Encoder / feature	将输入转换为中间表示的模块 / 中间表示。
Loss / objective	训练中优化的目标；检查每一项和它们的权重。
Pretraining / fine-tuning	先在其他任务或数据上训练，再将参数用于目标任务并可能继续训练。
Optimizer / learning rate	参数更新算法 / 控制更新的学习率设置。
Checkpoint	某一训练时刻保存的模型参数等状态。
Validation accuracy	验证集上的准确率；需查看是否用于模型选择。

读方法时先问：输入是什么？模型可学习的参数是什么？输出是什么？损失如何定义？用什么数据进行评估？随后检查数据划分、基线、评价协议和实验波动。

在一个简化的新视角合成例子中：输入可为多张图片及相机参数；模型学习场景表示；渲染器产生预测图片；损失比较预测与真实图片；最终在未用于训练的视角上评估。具体方法的表示、损失和评价协议可能不同。

10 自测与答案

1. 真实标签为 1，而预测正类概率为 0.1，交叉熵损失大还是小?
2. 反向传播与优化器更新有什么区别?
3. 2000 个样本，batch size 为 100，每个样本每轮使用一次且每批更新一次，一个 epoch 有多少次更新?
4. 训练准确率 99%，验证准确率 65%，可能说明什么？还要检查什么?

参考答案：（1）较大，$-\log(0.1) \approx 2.303$。（2）反向传播计算梯度，优化器利用梯度生成参数更新。（3）20 次。（4）可能存在过拟合；还应检查数据划分、分布差异、标签质量及训练与验证评测方式是否一致。

11 课件定位与来源

本笔记依据 MIT Introduction to Deep Learning, 6.S191, Lecture 1: *Introduction to Deep Learning*（Alexander Amini，2026 年 1 月 5 日），并添加解释、算例与论文阅读提示。课件页码：20–32 神经元与激活；33–43 网络；44–53 损失；54–70 优化与反向传播；71–91 学习率与批次；92–106 过拟合与正则化。

官方课程：https://introtodeeplearning.com/

官方课件：https://introtodeeplearning.com/slides/6S191_MIT_DeepLearning_L1.pdf